

统计部分期末题复习

徐楚航

5.30

1 正态总体检验

1.1 各种情形下的检验方法

这里展示了正态总体下一样本和两样本的均值方差检验。

	参数	H_0	H_1	检验统计量及其分布	否定域
一样本	σ^2 已知	$\mu = \mu_0$	$\mu \neq \mu_0$	$U = \frac{\sqrt{n}(\bar{X}-\mu_0)}{\sigma}$ $U \mid \mu = \mu_0 \sim N(0, 1)$	$ U > u_{\alpha/2}$
		$\mu \leq \mu_0$	$\mu > \mu_0$		$U > u_\alpha$
		$\mu \geq \mu_0$	$\mu < \mu_0$		$U < -u_\alpha$
	σ^2 未知	$\mu = \mu_0$	$\mu \neq \mu_0$	$T = \frac{\sqrt{n}(\bar{X}-\mu_0)}{S}$ $T \mid \mu = \mu_0 \sim t_{n-1}$	$ T > t_{n-1}(\alpha/2)$
		$\mu \leq \mu_0$	$\mu > \mu_0$		$T > t_{n-1}(\alpha)$
		$\mu \geq \mu_0$	$\mu < \mu_0$		$T < -t_{n-1}(\alpha)$
	μ 已	$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$\chi_\mu^2 = nS_\mu^2/\sigma_0^2$ $\chi_\mu^2 \mid \sigma_0^2 \sim \chi_n^2$	$nS_\mu^2/\sigma_0^2 < \chi_n^2(1-\alpha/2)$ 或 $nS_\mu^2/\sigma_0^2 > \chi_n^2(\alpha/2)$
		$\sigma^2 \leq \sigma_0^2$	$\sigma^2 > \sigma_0^2$		$nS_\mu^2/\sigma_0^2 > \chi_n^2(\alpha)$
		$\sigma^2 \geq \sigma_0^2$	$\sigma^2 < \sigma_0^2$		$nS_\mu^2/\sigma_0^2 < \chi_n^2(1-\alpha)$
	μ 未	$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$ $\chi^2 \mid \sigma_0^2 \sim \chi_{n-1}^2$	$(n-1)S^2/\sigma_0^2 < \chi_{n-1}^2(1-\alpha/2)$ 或 $(n-1)S^2/\sigma_0^2 > \chi_{n-1}^2(\alpha/2)$
		$\sigma^2 \leq \sigma_0^2$	$\sigma^2 > \sigma_0^2$		$(n-1)S^2/\sigma_0^2 > \chi_{n-1}^2(\alpha)$
		$\sigma^2 \geq \sigma_0^2$	$\sigma^2 < \sigma_0^2$		$(n-1)S^2/\sigma_0^2 < \chi_{n-1}^2(1-\alpha)$
两样本	σ_1^2 σ_2^2 已知	$\mu_2 - \mu_1 = \mu_0$	$\mu_2 - \mu_1 \neq \mu_0$	$U = \frac{\bar{Y}-\bar{X}-\mu_0}{\sqrt{\sigma_1^2/m+\sigma_2^2/n}}$ $U \mid \mu_0 \sim N(0, 1)$	$ U > u_{\alpha/2}$
		$\mu_2 - \mu_1 \leq \mu_0$	$\mu_2 - \mu_1 > \mu_0$		$U > u_\alpha$
		$\mu_2 - \mu_1 \geq \mu_0$	$\mu_2 - \mu_1 < \mu_0$		$U < -u_\alpha$
	σ_1^2 σ_2^2 未知	$\mu_2 - \mu_1 = \mu_0$	$\mu_2 - \mu_1 \neq \mu_0$	$T_w = \frac{\bar{Y}-\bar{X}-\mu_0}{S_w} \sqrt{\frac{mn}{m+n}}$ $T_w \mid \mu_0 \sim t_{n+m-2}$	$ T_w > t_{n+m-2}(\frac{\alpha}{2})$
		$\mu_2 - \mu_1 \leq \mu_0$	$\mu_2 - \mu_1 > \mu_0$		$T_w > t_{n+m-2}(\alpha)$
		$\mu_2 - \mu_1 \geq \mu_0$	$\mu_2 - \mu_1 < \mu_0$		$T_w < -t_{n+m-2}(\alpha)$
	μ_1 μ_2 已知	$\sigma_2^2 = \sigma_1^2$	$\sigma_2^2 \neq \sigma_1^2$	$F_* = \frac{S_{2*}^2}{S_{1*}^2}$ $F_* \mid \sigma_2^2=\sigma_1^2 \sim F_{n,m}$ $S_{1*}^2 = \frac{1}{m} \sum_{i=1}^m (X_i - \mu_1)^2$ $S_{2*}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \mu_2)^2$	$F_* < F_{n,m}(1-\alpha/2)$ 或 $F_* > F_{n,m}(\alpha/2)$
		$\sigma_2^2 \leq \sigma_1^2$	$\sigma_2^2 > \sigma_1^2$		$F_* > F_{n,m}(\alpha)$
		$\sigma_2^2 \geq \sigma_1^2$	$\sigma_2^2 < \sigma_1^2$		$F_* < F_{n,m}(1-\alpha)$
	μ_1 μ_2 未知	$\sigma_2^2 = \sigma_1^2$	$\sigma_2^2 \neq \sigma_1^2$	$F = \frac{S_2^2}{S_1^2}$ $F \mid \sigma_2^2=\sigma_1^2 \sim F_{n-1,m-1}$ $S_1^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2$ $S_2^2 = \frac{1}{n-1} \sum_{j=1}^n (Y_j - \bar{Y})^2$	$F < F_{n-1,m-1}(1-\alpha/2)$ 或 $F > F_{n-1,m-1}(\alpha/2)$
		$\sigma_2^2 \leq \sigma_1^2$	$\sigma_2^2 > \sigma_1^2$		$F > F_{n-1,m-1}(\alpha)$
		$\sigma_2^2 \geq \sigma_1^2$	$\sigma_2^2 < \sigma_1^2$		$F < F_{n-1,m-1}(1-\alpha)$

其中 $S_w = \sqrt{\frac{(m-1)S_1^2+(n-1)S_2^2}{m+n-2}}$.

注 1.1. 1. 成对数据往往作差转换为一样本问题。

2. 均值未知时 S^2 的分母是 $n - 1$, 均值已知时 S^2 的分母是 n , 对应的自由度也是 $n - 1$ 和 n .

1.2 相关期末题

例 1.1. 经大量调查, 已知一般健康成年男子每分钟脉搏的次数服从正态分布 $N(72, 6^2)$. 现测得 16 例成年男子慢性铅中毒患者的脉搏平均 67 次/分钟, 标准差为 7 次/分钟. 问在显著性水平 0.05 下, 这群患者每分钟脉搏的次数 (假设也服从正态分布) 和正常人有无显著性差异? (要求对均值和方差都进行检验.)

解. 1. 均值的检验. $H_0: \mu = 72, \longleftrightarrow H_1: \mu \neq 72$. 由 t 检验统计量

$$t = \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} = \frac{\sqrt{16}(67 - 72)}{7} = -2.857,$$

可知 $|t| > t_{15}(0.025) = 2.131$, 故应拒绝原假设, 即认为患者每分钟脉搏的平均次数与正常人有显著性差异.

2. 方差的检验. $H_0: \sigma^2 = 6^2, \longleftrightarrow H_1: \sigma^2 \neq 6^2$. 由 χ^2 检验统计量

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} = \frac{15 \cdot 7^2}{6^2} = 20.417,$$

可知 $\chi_{15}^2(0.975) = 6.262 < \chi^2 < \chi_{15}^2(0.025) = 27.488$, 故应接受原假设, 即认为患者每分钟脉搏次数的方差与正常人相同. 结合均值和方差两个方面, 我们最终可认为患者每分钟脉搏的次数与正常人有显著性差异.

□

下面这道题比较特殊, 其成对数据表面看上去是两样本问题, 但本质上是一样本问题。

例 1.2. 为了检验某种体育锻炼对减肥的效果, 随机抽取了 10 名减肥者进行测试. 在进行体育锻炼前后这些减肥者的体重 (单位: 千克) 数据列表如下, 问该体育锻炼方法对降低体重是否具有显著性 (设人的体重服从正态分布, 取显著性水平 $\alpha = 0.05$)?

锻炼前体重	70	65	67	58	69	72	74	61	63	67
锻炼后体重	68	60	68	58	67	70	70	60	60	65

解. 成对数据. 首先可算得相减之后, 有 $\bar{X} = 2, S^2 = 28/9$. 故由

$$t = \frac{\sqrt{n}\bar{X}}{S} = 3.59 > t_9(0.05) = 1.833,$$

可拒绝原假设 (H_0 : 锻炼前后体重无显著变化), 即认为该体育锻炼方法对降低体重具有显著性.

□

例 1.3. 在 2021 年日本东京举行的第 32 届夏季奥运会中, 我国运动员杨倩和杨皓然获得了射击混合双人团体 10 米气步枪金牌. 决赛中 15 轮射击结果如下 (单位: 环):

杨倩	10.5	9.7	10.0	10.5	10.3	10.2	10.1	10.6	10.4	9.9	10.8	10.8	10.4	10.4	10.4
杨皓然	10.3	10.4	10.9	10.2	10.5	10.4	10.2	10.8	10.6	10.0	10.5	10.7	10.4	10.1	10.7

设两位运动员的每次射击结果相互独立, 且均服从正态分布. 利用你所学的统计知识并结合上述决赛数据, 回答如下问题 (显著性水平 $\alpha = 0.05$):

1. 两位运动员在比赛中射击成绩的方差是否可以认为是相等的?
2. 假设“杨皓然平均射击水平高于杨倩”是否显著成立?

解. 先做一些计算. 杨倩: $n_1 = 15, \bar{x} = 10.333, (n_1 - 1)S_1^2 = 1.353$; 杨皓然: $n_2 = 15, \bar{y} = 10.447, (n_2 - 1)S_2^2 = 0.957; S_w^2 = 0.287^2$.

1. $H_0: \sigma_1^2 = \sigma_2^2 \leftrightarrow H_1: \sigma_1^2 \neq \sigma_2^2$. 由

$$0.336 = \frac{1}{F_{14,14}(0.025)} < \frac{S_1^2}{S_2^2} = 1.414 < F_{14,14}(0.025) = 2.979,$$

接受 H_0 , 即可以认为他们的发挥稳定性相同.

2. $H_0: \mu_1 \geq \mu_2 \leftrightarrow H_1: \mu_1 < \mu_2$. 由于

$$t = \frac{\bar{X} - \bar{Y}}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} = -1.08 > -t_{28}(0.05) = -1.701,$$

故接受 H_0 , 即不能认为杨皓然的比赛成绩显著高于杨倩.

□

2 点估计

2.1 矩估计

定义 2.1 (矩估计). 设有总体分布族 $\{f(x, \theta), \theta \in \Theta\}$, Θ 是参数空间, $g(\theta)$ 是定义在 Θ 上参数 θ 的函数, 它可以表示为总体分布的某些矩的函数, 即

$$g(\theta) = G(\alpha_1, \dots, \alpha_k; \mu_2, \dots, \mu_s).$$

设 $\mathbf{X} = (X_1, \dots, X_n)$ 是从上述分布族中抽取的简单样本, 将式中的 α_i 和 μ_j 分别用它们“自然”的矩估计量 a_{ni} 和 m_{nj} 代替, 得

$$\hat{g}(\mathbf{X}) = G(a_{n1}, \dots, a_{nk}; m_{n2}, \dots, m_{ns}),$$

则 $\hat{g}(\mathbf{X})$ 作为 $g(\theta)$ 的估计量, 称为 $g(\theta)$ 的矩估计量. 这种求矩估计量的方法称为矩法.

2.2 最大似然估计

定义 2.2 (似然函数). 设 $f(\mathbf{x}, \theta) = f(x_1, \dots, x_n, \theta)$ 为样本 $\mathbf{X} = (X_1, \dots, X_n)$ 的概率函数. 当 x 固定时, 把 $f(x, \theta)$ 看成 θ 的函数, 称为似然函数, 记为

$$L(\theta, \mathbf{x}) = f(\mathbf{x}, \theta), \quad \theta \in \Theta, \mathbf{x} \in \mathcal{X},$$

其中 Θ 为参数空间, $\mathcal{X}$ 为样本空间. 称 $\log L(\theta, \mathbf{x})$ 为对数似然函数, 记为 $l(\theta, \mathbf{x})$.

定义 2.3 (最大似然估计). 设 $\mathbf{X} = (X_1, \dots, X_n)$ 是从参数分布族 $\mathcal{F} = \{f(x, \theta), \theta \in \Theta\}$ 中抽取的简单随机样本, $L(\theta, \mathbf{x})$ 是似然函数, 若存在统计量 $\hat{\theta}^* = \hat{\theta}^*(\mathbf{X})$, 满足条件

$$L(\hat{\theta}^*, \mathbf{x}) = \sup_{\theta \in \Theta} L(\theta, \mathbf{x}), \quad \mathbf{x} \in \mathcal{X},$$

或等价地使得

$$l(\hat{\theta}^*, \mathbf{x}) = \sup_{\theta \in \Theta} l(\theta, \mathbf{x}), \quad \mathbf{x} \in \mathcal{X},$$

则称 $\hat{\theta}^*(\mathbf{X})$ 为 θ 的最大似然估计 (*maximum likelihood estimation, MLE*). 若待估函数是 $g(\theta)$, 则定义 $g(\hat{\theta}^*(\mathbf{X}))$ 为 $g(\theta)$ 的 *MLE*.

一般来说, 我们有两种方法获取最大似然估计。

1. 用微积分中求极值的方法

若似然函数 $L(\theta, \mathbf{x})$ 是 θ 的连续可微函数, 则可用微积分中求极值点的方法去求 θ 的最大似然估计, 即找使 $L(\theta, \mathbf{x})$ 达到最大时 θ 的值. 由于 $L(\theta, \mathbf{x})$ 和 $\log L(\theta, \mathbf{x}) = l(\theta, \mathbf{x})$ 具有相同的极值点, 可用 $l(\theta, \mathbf{x})$ 来代替 $L(\theta, \mathbf{x})$. 因为 $L(\theta, \mathbf{x})$ 一般是若干个函数的乘积, $l(\theta, \mathbf{x})$ 为若干个函数之和而较易于处理.

设 $\boldsymbol{\theta} = (\theta_1, \dots, \theta_k)$ 为参数向量 (特别当 $k = 1$, $\boldsymbol{\theta}$ 为参数). 若 $l(\boldsymbol{\theta}, \mathbf{x})$ 的极大值在参数空间 Θ 的内点处 (而非边界点) 达到, 则此点必为似然方程组

$$\frac{\partial l(\boldsymbol{\theta}, \mathbf{x})}{\partial \theta_i} = 0, \quad i = 1, 2, \dots, k$$

的解.

因此求极大似然估计首先求似然方程组的解 $\hat{\theta}^*$, 然后需要满足下列条件: (1) 似然函数的极大值在参数空间 Θ 内部达到; (2) 似然方程只有唯一解, 则似然方程之解 $\hat{\theta}^*$ 必为 θ 的最大似然估计.

2. 从定义出发

当似然函数 $L(\theta, \mathbf{x})$ 对参数 θ 不可微, 甚至不连续时, 似然方程一般没有意义, 不能采用上述方法, 必须直接从定义出发去求参数 θ 的极大似然估计.

例 2.1. 设 $\mathbf{X} = (X_1, \dots, X_n)$ 是从均匀分布族 $\{U(\theta, \theta + 1) : -\infty < \theta < +\infty\}$ 中抽取的简单样本, 求 θ 的最大似然估计.

解. 给定样本 $\mathbf{x}$ 时, θ 的似然函数为

$$L(\theta, \mathbf{x}) = \begin{cases} 1, & \theta < x_{(1)} \leq x_{(n)} < \theta + 1 \\ 0, & \text{其他} \end{cases} = \begin{cases} 1, & x_{(n)} - 1 < \theta < x_{(1)}, \\ 0, & \text{其他}. \end{cases}$$

这时, 似然函数只取 1 和 0 两个值, 只要 $x_{(n)} - 1 < \theta < x_{(1)}$ 都可使 L 达到极大. 故 θ 的最大似然估计不止一个, 如

$$\hat{\theta}_1^*(\mathbf{X}) = X_{(1)}, \quad \hat{\theta}_2^*(\mathbf{X}) = X_{(n)} - 1$$

都是 θ 的最大似然估计. 事实上对任给的 $0 \leq \lambda \leq 1$,

$$\hat{\theta}^*(\mathbf{X}) = \lambda \hat{\theta}_1^*(\mathbf{X}) + (1 - \lambda) \hat{\theta}_2^*(\mathbf{X}) = \lambda X_{(1)} + (1 - \lambda) (X_{(n)} - 1)$$

都是 θ 的最大似然估计, 故知 θ 的最大似然估计有无穷多个. □

2.3 无偏估计

定义 2.4 (偏差与无偏性). 设 $\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta_1, \theta_2, \dots, \theta_k)$ 的一个估计量, 称

$$E_{\theta}(\hat{g}(X_1, X_2, \dots, X_n)) - g(\theta_1, \theta_2, \dots, \theta_k)$$

为估计量 $\hat{g}$ 的偏差. 若对任一可能的 $(\theta_1, \theta_2, \dots, \theta_k) \in \Theta$, 都有

$$E_{\theta_1, \theta_2, \dots, \theta_k}(\hat{g}(X_1, X_2, \dots, X_n)) = g(\theta_1, \theta_2, \dots, \theta_k),$$

则称 $\hat{g}$ 是 $g(\theta_1, \theta_2, \dots, \theta_k)$ 的一个无偏估计量.

2.4 相关期末题

例 2.2. 设总体 X 的密度函数为

$$f(x) = \frac{2x}{a^2}, \quad 0 \leq x \leq a,$$

其中 $a > 0$ 为未知参数, 而 $X_1, X_2, \dots, X_n$ 是来自该总体的一组简单随机样本.

1. 求 a 的矩估计量 $\hat{a}_1$ 和极大似然估计量 $\hat{a}_2$;
2. 求 $p = P(0 < X < \sqrt{a})$ 的极大似然估计量 $\hat{p}$;
3. 问 $\hat{a}_1$ 和 $\hat{a}_2$ 是否为无偏估计? 若是, 请证明你的结论; 若不是, 请修正之.

解. 1. $E(X) = \frac{2}{3}a$, 矩估计量 $\hat{a}_1 = \frac{3}{2}\bar{X}$.

$L(a, \mathbf{x}) = (\frac{2}{a^2})^n \prod_{i=1}^n x_i$ 关于 a 单调递减, 极大似然估计量 $\hat{a}_2 = X_{(n)}$;

2. 由 $p = \frac{1}{a}$ 知其极大似然估计量为 $\hat{p} = 1/X_{(n)}$;

3. 矩估计 $\hat{a}_1$ 是无偏的, 因 $E(\hat{a}_1) = \frac{3}{2}E(\bar{X}) = \frac{3}{2}E(X) = a$; 而由 $X_{(n)}$ 的密度函数为

$$h(x) = n[F(x)]^{n-1}f(x) = \frac{2n}{a^{2n}}x^{2n-1}, \quad 0 < x < a,$$

知 $E(\hat{a}_2) = \frac{2n}{2n+1}a$. 故 $\hat{a}_2$ 不是无偏估计, 可修正为 $\hat{a}_2^* = \frac{2n+1}{2n}X_{(n)}$.

□

例 2.3. 已知总体 X 的概率密度函数为 $f(x) = (\theta + 1)x^\theta, 0 < x < 1$, 其中 $\theta > -1$ 为一未知参数. 设 $X_1, X_2, \dots, X_n$ 是来自该总体的一组简单随机样本.

1. 求 θ 的矩估计量 $\hat{\theta}$;
2. 求 $g(\theta) = \frac{1}{\theta+1}$ 的极大似然估计量 $\hat{g}$;
3. 问 $\hat{g}$ 是否为 $g(\theta)$ 的一个无偏估计? 证明你的结论.
4. 求常数 b , 使得对任意实数 x , 都有 $\lim_{n \rightarrow \infty} P(\sqrt{n}(\hat{g} - g(\theta))/b \leq x) = \Phi(x)$ 成立, 其中 $\Phi(x)$ 为标准正态分布函数.

解. 1. 由 $EX = \frac{\theta+1}{\theta+2}$, 解方程 $\frac{\theta+1}{\theta+2} = \bar{X}$ 可知 θ 的矩估计量 $\hat{\theta} = \frac{2\bar{X}-1}{1-\bar{X}}$.

2. 由题意, 似然函数 $L(\theta) = (\theta + 1)^n \prod_{i=1}^n x_i^\theta$, 从而对数似然函数为

$$l(\theta) = \ln L(\theta) = n \ln(\theta + 1) + \theta \sum_{i=1}^n \ln x_i.$$

令 $\frac{dl(\theta)}{d\theta} = 0$, 可得 $\frac{n}{\theta+1} + \sum_{i=1}^n \ln x_i = 0$. 由此可知, $g(\theta) = \frac{1}{\theta+1}$ 的极大似然估计量

$$\hat{g} = -\frac{1}{n} \sum_{i=1}^n \ln X_i.$$

3. 记 $Y_i = -\ln X_i, i = 1, 2, \dots, n$, 则由密度变换公式知 $\{Y_i, 1 \leq i \leq n\}$ 独立同分布于参数为 $\theta + 1$ 的指数分布, 由此即知 $E\hat{g} = \frac{1}{\theta+1}$. 故 $\hat{g}$ 是 $g(\theta)$ 的一个无偏估计.

4. 由上可知, $\hat{g}$ 可表示为一列独立同分布随机变量 $\{Y_i, 1 \leq i \leq n\}$ 的平均, 故由经典场合下的中心极限定理可知, 常数 $b = \sqrt{\text{Var}(Y_1)} = \frac{1}{\theta+1}$.

□

下面一题就是最小二乘法的推导。

例 2.4. 设一系列随机变量 $Y_1, Y_2, \dots, Y_n$ 满足

$$Y_i = \beta x_i + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

其中 $x_1, x_2, \dots, x_n$ 为给定非负常数且不全相等, $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 相互独立且均服从正态分布 $N(0, \sigma^2)$, 而 β 和 σ^2 为两个未知参数.

1. 根据 $Y_1, Y_2, \dots, Y_n$ 的分布, 请写出似然函数 $L(\beta, \sigma^2)$.
2. 试求 β 的极大似然估计量 $\hat{\beta}$, 并证明 $\hat{\beta}$ 为 β 的一个无偏估计.
3. 证明 $\hat{\beta}^* = \sum_{i=1}^n Y_i / \sum_{i=1}^n x_i$ 也为 β 的一个无偏估计, 并比较 $\hat{\beta}$ 和 $\hat{\beta}^*$ 哪个更有效.

解. 1. 由 $Y_i \sim N(\beta x_i, \sigma^2), i = 1, 2, \dots, n$ 及它们相互独立可知,

$$L(\beta, \sigma^2) = \frac{1}{(\sqrt{2\pi}\sigma)^n} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta x_i)^2 \right\}.$$

2. 记对数似然函数 $l(\beta, \sigma^2) = \ln L(\beta, \sigma^2)$, 并令 $\frac{\partial l}{\partial \beta} = 0$ 可得, $\sum_{i=1}^n (y_i - \beta x_i) x_i = 0$, 即 β 的极大似然估计量为

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i Y_i}{\sum_{i=1}^n x_i^2}.$$

由 $\hat{\beta}$ 为一列独立正态随机变量的线性组合, 故 $\hat{\beta}$ 也服从正态分布, 且其期望和方差为

$$E(\hat{\beta}) = \frac{\sum_{i=1}^n \beta x_i^2}{\sum_{i=1}^n x_i^2} = \beta, \quad \text{Var}(\hat{\beta}) = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}.$$

从而 $\hat{\beta}$ 为 β 的一个无偏估计.

3. 与 $\hat{\beta}$ 类似, 估计量 $\hat{\beta}^*$ 也是一列独立正态随机变量的线性组合, 且

$$E(\hat{\beta}^*) = \frac{\sum_{i=1}^n \beta x_i}{\sum_{i=1}^n x_i} = \beta, \quad \text{Var}(\hat{\beta}^*) = \frac{n\sigma^2}{(\sum_{i=1}^n x_i)^2}.$$

故 $\hat{\beta}^*$ 也为 β 的一个无偏估计, 且由 Cauchy-Schwarz 不等式可知, 当 $x_1, x_2, \dots, x_n$ 不全相等时, $\text{Var}(\hat{\beta}) < \text{Var}(\hat{\beta}^*)$, 从而 $\hat{\beta}$ 更有效.

□

3 拟合优度检验

3.1 理论分布完全已知且只取有限个值

对于检验问题:

$$H_0: P(X = a_i) = p_i, \quad i = 1, 2, \dots, k \leftrightarrow H_1: \exists j \text{ s.t. } P(X = a_j) \neq p_j.$$

列表如下:

类别	a_1	a_2	$\dots$	a_i	$\dots$	a_k
理论值 (E)	np_1	np_2	$\dots$	np_i	$\dots$	np_k
观测值 (O)	n_1	n_2	$\dots$	n_i	$\dots$	n_k
$E - O$	$np_1 - n_1$	$np_2 - n_2$	$\dots$	$np_i - n_i$	$\dots$	$np_k - n_k$

皮尔逊统计量即是

$$Z = \sum \frac{(O - E)^2}{E} = \sum_{i=1}^k \frac{(np_i - n_i)^2}{np_i} = \sum_{i=1}^k \frac{n_i^2}{np_i} - n.$$

定理 3.1 (皮尔逊 χ^2 检验). 如果原假设 H_0 成立, 那么当样本量 $n \rightarrow \infty$ 时, Z 的分布趋于自由度为 $k - 1$ 的 χ^2 分布, 即 χ_{k-1}^2 .

3.2 理论分布类型已知但含有有限个未知参数

首先考虑总体 X 取有限个值 $\{a_1, a_2, \dots, a_k\}$. 此时分布中含有 r 个未知的参数 $\theta_1, \theta_2, \dots, \theta_r$, 即原假设为

$$H'_0: P(X = a_i) = p_i(\theta_1, \theta_2, \dots, \theta_r), \quad i = 1, 2, \dots, k,$$

记样本为 $(X_1, X_2, \dots, X_n)$, 在原假设 H'_0 下, 参数 $\theta_1, \theta_2, \dots, \theta_r$ 的最大似然估计为 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_r$, 从而 p_i 的最大似然估计为 $\hat{p}_i = p(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_r)$, $i = 1, 2, \dots, k$. 用 n_i 表示样本中取 a_i 的个数 ($i = 1, 2, \dots, k$), 则构建统计量

$$Z = \sum \frac{(O - \hat{E})^2}{\hat{E}} = \sum_{i=1}^k \frac{(n_i - n\hat{p}_i)^2}{n\hat{p}_i} = \sum_{i=1}^k \frac{n_i^2}{n\hat{p}_i} - n.$$

有如下的结论:

定理 3.2. 在一定的条件下, 若原假设 H'_0 成立, 则当 $n \rightarrow \infty$ 时, Z 的分布趋于自由度为 $k - r - 1$ 的 χ^2 分布, 即 χ_{k-r-1}^2 .

然后考虑总体 X 取无穷多个值, 但其分布中仅含有有限个未知参数. 此时原假设可以表示为

$$H_0'' : X \sim F_\theta(x), x \in \mathbb{R},$$

其中 $\theta = (\theta_1, \theta_2, \dots, \theta_r)$ 为未知参数, 它们在一定区域内变化. 我们可以将总体的取值切为 k 段, 记切分出的区间为

$$(x_0, x_1], (x_1, x_2], (x_2, x_3], \dots, (x_{k-2}, x_{k-1}], (x_{k-1}, x_k),$$

其中 $x_0 = -\infty, x_k = \infty$, 则定义离散型随机变量

$$Y = a_i, \quad x_{i-1} < X \leq x_i, i = 1, 2, \dots, k.$$

则当原假设 H_0'' 成立时, 随机变量 Y 的分布为

$$P(Y = a_i) = p_i(\theta_1, \theta_2, \dots, \theta_r), \quad i = 1, 2, \dots, k.$$

其中 $p_i(\theta_1, \theta_2, \dots, \theta_r) = F_\theta(x_i) - F_\theta(x_{i-1})$. 所以, 如果拒绝了假设的理论分布, 那么有理由拒绝原假设 H_0'' . 也就是说, 我们将检验假设 H_0'' 的问题转换为检验理论分布对应的假设 H_0' 的问题.

3.3 列联表检验

B	A						和
	1	2	...	i	...	a	
1	n_{11}	n_{21}	...	n_{i1}	...	n_{a1}	$n_{.1}$
2	n_{12}	n_{22}	...	n_{i2}	...	n_{a2}	$n_{.2}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
j	n_{1j}	n_{2j}	...	n_{ij}	...	n_{aj}	$n_{.j}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
b	n_{1b}	n_{2b}	...	n_{ib}	...	n_{ab}	$n_{.b}$
和	$n_{1.}$	$n_{2.}$	...	$n_{i.}$	...	$n_{a.}$	n

要检验

$$H_0 : A \text{ 和 } B \text{ 独立.}$$

检验统计量为

$$\begin{aligned} Z &= \sum_{i=1}^a \sum_{j=1}^b \frac{(n_{ij} - n_{i.} \cdot n_{.j} / n)^2}{n_{i.} n_{.j} / n} \\ &= \sum_{i=1}^a \sum_{j=1}^b \frac{(nn_{ij} - n_{i.} n_{.j})^2}{nn_{i.} n_{.j}}. \end{aligned}$$

当 $n \rightarrow \infty$ 时, Z 的渐近分布是自由度为 $(a-1)(b-1)$ 的 χ^2 分布, 即 $\chi_{(a-1)(b-1)}^2$.

3.4 齐一性检验

设有 r 个总体 $X^{(1)}, \dots, X^{(r)}$, 它们可能的取值都相同, 为 $a_1, \dots, a_s$, 且第 i 个总体 $X^{(i)}$ 取值为 a_j 的概率记为 $p_i(j), j = 1, 2, \dots, s; i = 1, 2, \dots, r$, 则要求检验假设: “这 r 个总体具有相同分布”, 可写成

$$H_0: p_1(j) = p_2(j) = \dots = p_r(j), \quad j = 1, 2, \dots, s.$$

其次, 从第 i 个总体中抽取大小为 n_i 的样本, 其中取值为 a_j 的有 n_{ij} 个, $j = 1, \dots, s; i = 1, \dots, r$, 可得到下表.

X	A						和
	1	2	...	j	...	s	
1	n_{11}	n_{12}	...	n_{1j}	...	n_{1s}	$n_{1.}$
2	n_{21}	n_{22}	...	n_{2j}	...	n_{2s}	$n_{2.}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
i	n_{i1}	n_{i2}	...	n_{ij}	...	n_{is}	$n_{i.}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
r	n_{r1}	n_{r2}	...	n_{rj}	...	n_{rs}	$n_{r.}$
和	$n_{.1}$	$n_{.2}$	...	$n_{.j}$	...	$n_{.s}$	n

此表与上表完全相似, 因此也称为 $r \times s$ 列联表. 但要注意到二者有一显著的不同, 即在此表中诸 $n_{i.}$ 是事先选定之数, 它没有随机性. 而上表中它与抽样结果有关, 因而 $n_{i.}$ 是随机的.

有一个比较容易理解的例子: 设有 r 个生产同一产品的工厂, 产品分为 s 个等级. 第 i 个工厂的 j 等品率为 $p_i(j), j = 1, 2, \dots, s; i = 1, 2, \dots, r$. “ r 个工厂产品质量相同”, 理解为等级品率都相同. 于是 “ r 个工厂产品质量齐一” 即为原假设.

若分布完全已知, 即

$$p_1(j) = \dots = p_r(j) = p_j^0, \quad j = 1, 2, \dots, s,$$

而 $p_1^0, \dots, p_s^0$ 皆已知且满足 $\sum_{j=1}^s p_j^0 = 1$, 这时

$$Z = \sum_{i=1}^r \sum_{j=1}^s \frac{(n_{ij} - n_{i.} p_j^0)^2}{n_{i.} p_j^0},$$

则由定理3.1可知, 当 H_0 成立且 $n_i \rightarrow \infty (i = 1, \dots, r)$ 时有

$$Z \rightarrow \chi_{(s-1)r}^2.$$

若分布未知, 即

$$p_1(j) = \dots = p_r(j) = p_j, \quad j = 1, 2, \dots, s,$$

而 $p_1, \dots, p_s$ 皆未知. 这时

$$\hat{Z}_{ni}^* = \sum_{j=1}^s \frac{(n_{ij} - n_{i.} \hat{p}_j^*)^2}{n_{i.} \hat{p}_j^*} = n \sum_{j=1}^s \frac{(n_{ij} - n_{i.} n_{.j}/n)^2}{n_{i.} n_{.j}}, \quad i = 1, \dots, r,$$

故总的 $\hat{Z}_n^*$ 为

$$\begin{aligned}\hat{Z}^* &= \hat{Z}_n^* = \sum_{i=1}^r \hat{Z}_{ni}^* = n \sum_{i=1}^r \sum_{j=1}^s \frac{(n_{ij} - n_{i\cdot}n_{\cdot j}/n)^2}{n_{i\cdot}n_{\cdot j}} \\ &= n \left(\sum_{i=1}^r \sum_{j=1}^s \frac{n_{ij}^2}{n_{i\cdot}n_{\cdot j}} - 1 \right).\end{aligned}$$

在齐一性问题中, 第 i 个总体中抽取的样本 $n_{i\cdot}$ 是事先给定的, 它没有随机性. 而在独立性问题中 $n_{i\cdot}$ 并未事先指定, 它是随机变量. 有了这个重要差别, 定理3.2 就不能直接用于齐一性检验问题中, 必须从头研究 $\hat{Z}_n^*$ 的分布, 但经过复杂的论证, 证明了在齐一性问题中若假设 H_0 成立, 则当 $n_{i\cdot} \rightarrow \infty (i = 1, 2, \dots, r)$ 时, 则 $\hat{Z}^*$ 的极限分布仍为 $\chi_{(r-1)(s-1)}^2$.

3.5 相关期末题

例 3.1. 中国科学技术大学 2019 级本科新生入学考试中, 某学院两个班级的英语科目各档成绩 (从低到高) 人数如下表所示:

档次	I	II	III	IV	V	VI	合计
一班	8	27	10	6	8	6	65
二班	15	25	8	7	6	4	65

我们能否认为这两个班级的英语水平大致相当? 显著性水平设为 $\alpha = 0.05$.

解. 齐一性检验. 原假设为两个班级的英语水平相当, 而其检验统计量为

$$\chi^2 = \sum_{i=1}^2 \sum_{j=1}^6 \frac{(nn_{ij} - n_{i\cdot}n_{\cdot j})^2}{nn_{i\cdot}n_{\cdot j}}.$$

代入数据计算可知, $\chi^2 = 3.1922 < \chi_5^2(0.05) = 11.071$, 故在显著性水平 $\alpha = 0.05$ 下我们不能拒绝原假设, 即可认为两个班级的英语水平相当. $\square$

例 3.2. 某种鸟在起飞前, 双足齐跳的次数 X 服从参数为 p 的几何分布, 即其分布律为 $P(X = k) = p(1 - p)^{k-1}, k = 1, 2, \dots$. 某人观测 130 次后, 获得一组样本如下:

k	1	2	3	4	5	6	7	8	9	10	11	12	≥ 13
频数	48	31	20	9	6	5	4	2	1	1	2	1	0

1. 求 p 的最大似然估计值 (精确到小数点后三位);
2. 在拟合优度检验中频数一般不能小于 5, 故需将上述所有 $k \geq 7$ 情形下的频数进行合并, 此时请检验假设 “ X 服从几何分布” 是否成立 (显著性水平 $\alpha = 0.05$).

解. 1. 对几何分布总体, 易知其参数 p 的极大似然估计值为

$$\hat{p} = \frac{1}{\bar{X}} = \frac{130}{363} = 0.358.$$

2. 合并后的数据为

k	1	2	3	4	5	6	≥ 7
频数	48	31	20	9	6	5	11

从而检验统计量

$$\begin{aligned}\chi^2 &= \frac{(48 - 130 \times \hat{p})^2}{130 \times \hat{p}} + \frac{[31 - 130 \times \hat{p}(1 - \hat{p})]^2}{130 \times \hat{p}(1 - \hat{p})} + \cdots + \frac{[11 - 130 \times (1 - \hat{p})^6]^2}{130 \times (1 - \hat{p})^6} \\ &= 1.868 < \chi_5^2(0.05) = 11.071\end{aligned}$$

故接受原假设.

□

注 3.1. 事实上, 列联表检验和齐一性检验十分相似, 最主要的区别就在于看行和或者列和是否是事先选定之数, 若是事先选定也就是没有随机性即为齐一性检验, 否则为列联表检验。下面有两个典型例子。

例 3.3. 上海证券综合指数简称“上证指数”, 反映了上海证券交易所上市股票价格的变动情况. 自上证指数诞生的二十七年 (1991 年 1 月至 2017 年 12 月) 以来, 所有月份上涨或下跌的情况如下:

月份	一	二	三	四	五	六	七	八	九	十	十一	十二
上涨月数	14	21	16	15	14	14	13	15	11	13	18	13
下跌月数	13	6	11	12	13	13	14	12	16	14	9	14

结合你所学的知识, 我们能否认为上证指数的涨跌与月份有关?

解. 齐一性检验. 两行的和分别为 177 和 147, 每列之和均为 27. 由此可算得 χ^2 统计量的值为 $11.394 < \chi_{11}^2(0.05) = 19.675$, 故可认为“无充分证据表明上证指数的涨跌与月份有关”或“上证指数的涨跌与月份无关”. □

例 3.4. 为研究色盲是否与性别有关, 调查 1000 人, 结果见下表

	男	女	Σ
正常	442	514	956
色盲	38	6	44
Σ	480	520	1000

问色盲是否与性别有关 ($\alpha = 0.01$).

解. 列联表检验. 检验问题为 H_0 : 色盲和性别独立.

此例中 $n = 1000, r = s = 2$, 查表 $\chi_{(r-1)(s-1)}^2(\alpha) = \chi_1^2(0.01) = 6.64$. 可计算检验统计量

$$Z = \frac{1000(442 \times 6 - 514 \times 38)^2}{956 \times 44 \times 480 \times 520} = 27.14 > \chi_1^2(0.01) = 6.64,$$

拒绝原假设. 这表明色盲和性别有非常密切的关系.

□